

梁伟业

Agent应用开发



男 | 21岁

重庆 巴南

17823689449

lwxiaoye@163.com

专业技能 Skills

- ★ LangGraph、LangChain、ReAct、Function Calling、MCP、Skills、Harness Engineering、RAG、
- ★ 掌握文档切片、向量检索、Embedding、上下文拼接和知识图谱检索
- ★ 熟悉 GPT、Claude、Gemini、GLM、Qwen 等 LLM API，了解 Ollama 本地部署
- ★ 擅长场景化 Prompt、JSON 结构化输出和结果校验
- ★ AI 增强开发：深度使用 Claude Code (CLI)、Codex、cursor 等 AI 编程工具进行高效率开发，具备较强的 AI 协同编程

教育 Education

- 重庆工程学院

全日制本科

软件工程

2023/09 — 2027/06

在校荣誉 Honou

- 2023-2024年度优秀学生助理
- 2025年度文物青年说三等奖
- 2025年度NCDA比赛三等奖
- 2025年度第四届网络文化节一等奖
- 2023-2026年度学院第二课堂一等奖
- 省级奖项3次、校级奖项9次、校级立项项目2次、院级奖项10次

关于我 About me

对新技术保持持续学习的习惯，遇到不熟悉的问题会主动查资料、做验证，再把可行方案落到项目里。

有较强的责任心，负责的模块会把流程跑完整，包括需求理解、功能开发、联调测试和问题修复。

对 AI 应用开发有长期兴趣，关注模型能力如何真正服务业务场景，而不是停留在简单调用接口。

项目经历 Experience 1

2026年5月1日 — 2026年6月4日

CareerForge-AI 高校学生就业辅助平台

Agent 应用开发（全栈开发）

技术栈：FastAPI、React、TypeScript、MySQL、Redis、SSE、Function Calling、Harness Engineering、RAG

项目网址：<https://lwxiaoye.top>

★【项目介绍】

面向高校学生的就业辅助系统，主要包括简历助手、模拟面试、面试报告和管理后台。学生可以使用在线简历，通过对话完成简历优化，也可以基于简历和目标岗位进行模拟面试；后台支持模型、智能体、Skill 和系统参数配置。

★【技术亮点】

- 实现AI 简历助手 **Agentic Loop**，基于 **Function Calling** 将简历读取、生成、优化、局部更新、PDF 导出封装为工具，由后端 **Harness** 统一执行和校验，避免模型直接写库带来的不可控风险。
- 在简历优化链路中加入质量检查，围绕强动词、量化结果、JD 覆盖度、项目描述长度等指标做约束，使 **AI** 输出更接近可投递、可面试的简历内容。

★【我的职责】

- 为模型输出增加 **Harness** 校验和兜底逻辑，处理字段缺失、分数异常、问题过泛、报告为空等情况，保证面试不会因为一次模型异常直接中断。
- 独立负责AI 面试官核心模块开发，完成简历驱动提问、逐轮追问、回答评分、语音提交、报告生成和前端实时反馈等功能。
- **Prompt 工程 + 安全护栏**：独立设计 3 套 **System Prompt**（面试官人格/安全红线/防注入/反套路），动态上下文注入逻辑，6 维 **Rubric** 评分标准
- 设计面试官 **RAG** 链路，将岗位知识、技术知识点和面试参考资料接入面试流程，通过文档切片、Embedding 向量检索、关键词召回和上下文拼接，为问题生成和追问提供依据。
- 同时完成 **AI** 简历助手核心链路，包括 **Agentic Loop** 工具调用、简历读取、生成优化、版本检查、写前快照和撤销恢复，使简历助手可以真正操作在线简历，而不是只给文字建议。

项目经历 Experience 2

2026年2月15日 — 2026年4月29日

项目经历·多智能体客服系统

Agent 应用开发（全栈开发）

技术栈：Python、LangGraph、LangChain、Flask SSE、Docker

项目网址：<https://lwxiaoye.top>

★【项目介绍】

LangGraph 搭建的多智能体客服平台，核心思路是用一个“调度中心 + 多个专业 Agent”的架构来处理客服场景。用户发来消息后，系统先用 LLM 做意图分类，然后路由给对应的专业 Agent 去处理。每个 Agent 有自己的领域知识库和 prompt 设定，回答风格和内容都不一样。

作品集 Portfolio

荣誉链接:

https://pan.baidu.com/s/10k62vkYyRAtblmk_FKIMyw?pwd=tb26

项目链接:

<https://github.com/Dloading666/CareerForge-AI>

项目链接:

<https://github.com/lwxiaoye/Springboot-RPA>

兴趣 Interest

- 羽毛球
- 篮球
- 摄影

★【技术亮点】

- LangGraph 状态图编排: 用 StateGraph 把分类→路由→Agent 处理→回复生成串成一条 pipeline, 节点之间通过条件边做动态路由。
- 护栏机制: 分类阶段如果识别出 out-of-scope 的内容(越狱、闲聊、违法类), 直接短路返回固定回复, 不经过任何业务 Agent, 防止模型被带偏。
- 双层会话管理: LangGraph checkpoint 做跨进程持久化 + SessionManager 做本地缓存, 两边互补, 既保证可靠性又不牺牲响应速度。
- 模块化 Agent 基类: 所有专业 Agent 继承 BaseAgent, 统一了 process() 接口和上下文注入方式, 加一个新 Agent 只需要写 prompt 和知识库, 不用改 workflow 代码。

★【我的职责】

- 负责项目从零搭建, 完成技术选型与核心架构设计。选定 LangGraph 作为 workflow 引擎——以显式状态图替代隐式 Agent 路由, 使业务流程可读、可调试、可增量扩展。该架构支持后续快速迭代, 新增业务 Agent 仅需添加节点与条件边, 无需改动已有模块。
- 设计并实现分类标签规范化模块, 将意图分类准确率从约 70% 提升至约 95%。针对 LLM 分类输出格式不稳定的问题(多行输出、夹杂标点、中英混排), 编写 normalize_classifier_label 多层清洗函数, 通过去空白、取首词、按长度降序匹配等策略消除解析歧义, 配合 out-of-scope 护栏实现安全兜底。
- 主导前端交互体验优化, 将对话模式从同步请求升级为 SSE 流式输出。同步模式下用户等待时间达 5-6 秒无反馈, 改为 SSE 流式 + 打字机效果后, 首字延迟压缩至毫秒级。同步处理了移动端触摸适配、剪贴板 API 降级、Markdown 渲染库 CDN 容灾等边界场景, 覆盖生产环境真实异常路径。
- 重构会话持久化方案, 解决分布式部署场景下的状态丢失问题。在 LangGraph Server 多进程环境下无法跨请求保持对话上下文。改造为 checkpointer 持久化

项目经历 Experience 3

2025年10月15日 — 2025年12月29日

项目经历 · 医疗领域RAG系统

Agent 应用开发 (全栈开发)

技术栈: Python、LangGraph、LangChain、Flask
SSE、Docker、Milvus、BM25

项目网址: <https://lwxiaoye.top>

★项目介绍: 面向医疗场景的检索增强生成系统, 解决通用大模型医学知识不足与通用 RAG 检索精度不够两个核心问题。基于 LangGraph 构建 Agent 工作流, 支持查询改写、子问题拆分、联网搜索增强与事实核验, 实现从数据入库到检索生成再到质量评测的完整闭环。多轮问诊 Agent 支持主动追问与用户背景动态维护

★【技术亮点】

- 稠密+稀疏混合检索: 同一文档在 Milvus 中维护三个向量字段, 多路召回后经 RRF 融合排序。稠密向量捕获语义关联, BM25 稀疏向量保证专有名词精确匹配, 实测召回率 91.3%、精确率 92.1%。
- Token 预算控制 + 对话摘要压缩: 基于 tiktoken 做实时 token 估算, 超出上下文阈值时自动触发 LLM 摘要压缩, 在保留关键信息的前提下控制 prompt 长度, 避免上下文溢出

★【我的职责】

- 搭建全链路医疗 RAG 系统, 覆盖数据入库、向量存储、混合检索、Agent 工作流。
- 将线性 RAG 链路重构为 Agent 自纠错闭环, 增加检索质量评估、联网搜索补充、事实核验三个节点, 失败自动回退重试, 有效降低幻觉输出
- 实现多轮问诊的信息收集与并行检索协同机制, Agent 主动追问补全缺失信息后自动拆分子查询并行检索, 兼顾信息完整性和响应速度。
- 建设 FastAPI 后端基础设施, 包括用户认证体系、会话持久化、模型配置管理后台和 SSE 流式推送。实现了完整的注册登录、Token 鉴权、多服务类型的会话历史隔离存储。